

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM

TRƯỜNG ĐẠI HỌC

Độc Lập - Tự Do - Hạnh Phúc

CÔNG NGHỆ THÔNG TIN

ĐỀ CƯƠNG CHI TIẾT

Tên đề tài tiếng Việt: Nghiên cứu và xây dựng bộ dữ liệu hỏi đáp qua video dựa trên bằng chứng về tai nạn giao thông tại Việt Nam

Tên đề tài tiếng Anh: Research and Construction of an Evidence-Grounded Video Question Answering Dataset for Traffic Accidents in Vietnam

Cán bộ hướng dẫn (Học vị, họ và tên): TS. Đỗ Trọng Hợp và ThS. Nguyễn Ngọc Quý - Khoa Công nghệ Phần mềm, Trường Đại học Công nghệ Thông tin, ĐHQG-HCM

Ngôn ngữ thực hiện: Tiếng Việt

Thời gian thực hiện: Từ ngày 07/09/2026 đến ngày 26/12/2026

Sinh viên thực hiện:

Nguyễn Minh Quốc – MSSV: 23521304

Nguyễn Văn Quyền – MSSV: 23521329

Hệ đào tạo: Chính quy

Nội dung đề tài:

Tổng quan đề tài

Trong những năm gần đây, các mô hình thị giác - ngôn ngữ (Vision-Language Models) và hệ thống hỏi đáp qua video (VideoQA) đã đạt được nhiều tiến bộ vượt bậc về năng lực nhận thức đa phương thức, tiêu biểu qua sự ra đời của hàng loạt mô hình nền tảng mạnh mẽ như Flamingo [1], LLaVA [2] hay Video-LLaMA [3]. Để đo năng lực hiểu video của các mô hình này, cộng đồng nghiên cứu sử dụng các bộ chuẩn đánh giá chung như Video-MME [4]. Đến năm 2025, Gemini 2.5 Pro được báo cáo đạt 84,8% trên bộ chuẩn này [5]. Tiến bộ này đã được đưa vào lĩnh vực giao thông. Ví dụ, SeeUnsafe [6] dùng mô hình đa phương thức để phân loại va chạm và tình huống suýt va chạm từ video camera giao thông, còn TABot [7] được huấn luyện riêng cho các tác vụ về tai nạn. Tuy nhiên, khi được đánh giá riêng trên video tai nạn, các mô hình vẫn bộc lộ điểm yếu rõ ràng. Trên VRU-Accident [8], mô hình trả lời khá tốt các thuộc tính nhìn thấy trực tiếp, ví dụ thực thể tham gia giao thông và môi trường, nhưng gặp khó khi suy luận về nguyên nhân, loại tai nạn và khả năng phòng tránh. CrashSight [9] cũng ghi nhận mô hình mô tả khung cảnh tốt nhưng yếu về trình tự thời gian và quan hệ nhân quả. Ngoài ra, Xiao và cộng sự [10] chỉ ra rằng mô hình có thể chọn đúng đáp án nhưng không chỉ ra được đoạn video làm bằng chứng. Như vậy, một câu trả lời đúng chưa chắc đã dựa trên việc thực sự xem video.

Để biết một mô hình có dùng được cho video tai nạn ở Việt Nam hay không, cần một bộ chuẩn đánh giá có dữ liệu giống với thực tế ở Việt Nam. Các bộ chuẩn hiện có chưa đáp ứng yêu cầu này ở ba điểm. Thứ nhất, chưa có bộ nào được xây dựng riêng cho dòng xe hỗn hợp có nhiều xe máy như ở Việt Nam. Một số bộ còn giới hạn loại va chạm, ví dụ VRU-Accident không bao gồm va chạm giữa các xe máy với nhau (chủ yếu ô tô và người đi bộ) [8]. Thứ hai, phần lớn dùng dạng câu hỏi trắc nghiệm [8, 12, 13], nên chưa đánh giá được khả năng mô hình tự diễn đạt câu trả lời. Thứ ba, các bộ chuẩn này không yêu cầu mô hình chỉ ra bằng chứng, nên không kiểm tra được câu trả lời đúng có dựa vào nội dung video hay không [10].

Từ những hạn chế trên, đề tài xây dựng VN-TA-VQA, một bộ chuẩn hỏi đáp dạng trả lời tự do trên video tai nạn và tình huống nguy hiểm giao thông tại Việt Nam. Video được thu thập từ các nguồn công khai, nhưng chỉ giữ lại các vụ tai nạn và tình huống nguy hiểm xảy ra tại Việt Nam, bao gồm nhiều góc quay như camera hành trình, camera giám sát và video do người dân ghi lại. Mỗi cặp hỏi – đáp được gắn thêm nhãn mốc thời gian bằng chứng: 1–3 khung hình trong video cho thấy câu trả lời. Bộ

chuẩn này cho phép đánh giá mô hình trên đúng loại video và loại tai nạn phổ biến ở Việt Nam, đồng thời kiểm tra câu trả lời của mô hình có dựa trên bằng chứng trong video hay không.

Các công trình liên quan

Về dữ liệu

Các bộ dữ liệu tai nạn ban đầu chủ yếu phục vụ việc phát hiện tai nạn, chưa có hỏi đáp. Ví dụ, DoTA [12] gán nhãn thời điểm bất thường trong video camera hành trình. SUTD-TrafficQA [13] là một trong những bộ đầu tiên chuyển sang hỏi đáp, với 10.080 video và 62.535 câu hỏi trắc nghiệm thuộc 6 nhóm suy luận. Đến năm 2024, MM-AU [11] mở rộng lên 11.727 video góc nhìn từ xe, kèm 58.650 cặp lý do tai nạn thuộc 58 loại, nhưng câu hỏi vẫn ở dạng trắc nghiệm. TAU-106K [7] đi theo hướng tăng quy mô: gom khoảng 106 nghìn video và ảnh từ các bộ có sẵn và nền tảng công khai để huấn luyện mô hình chuyên biệt. Thay vì bao quát mọi loại tai nạn, Kim và cộng sự (2025) chọn thu hẹp đối tượng với VRU-Accident [8]. Bộ này chỉ gồm các vụ va chạm giữa xe và người tham gia giao thông dễ bị tổn thương, mà nhóm tác giả định nghĩa là người đi bộ và người đi xe đạp. Bộ có 1.000 video camera hành trình, 6.000 câu trắc nghiệm bốn lựa chọn và 1.000 đoạn mô tả chi tiết. Vì phạm vi được định nghĩa như vậy, va chạm giữa các xe máy với nhau, vốn là dạng tai nạn phổ biến ở Việt Nam [14, 15], nằm ngoài phạm vi của bộ dữ liệu. Khác với hai bộ trên dùng camera hành trình, một số công trình gần đây dùng camera đặt cố định bên đường. RoadSceneVQA [16] thuộc nhóm này. Đây là bộ dữ liệu hỏi đáp cho hệ thống camera giám sát đặt cố định bên đường, gồm 34.736 cặp hỏi – đáp. Các câu hỏi không chỉ hỏi đặc điểm nhìn thấy được của phương tiện và người đi đường, mà còn hỏi họ định làm gì tiếp theo, hành vi có đúng luật hay không và các bên tương tác với nhau ra sao. Nhóm tác giả đề xuất thêm mô hình RoadMind, gồm module hợp nhất thị giác – ngôn ngữ CogniAnchor Fusion và chuỗi suy luận AD-CoT. Tuy vậy, bộ dữ liệu hướng đến hiểu tình huống giao thông nói chung, không chuyên về tai nạn. CrashSight [9] cũng dùng camera ven đường nhưng tập trung vào va chạm, với 250 video và 13.000 câu trắc nghiệm.

Về mô hình và phương pháp

VLM tổng quát: LLaVA [2], InternVL [17], Qwen2.5-VL [18] là các mô hình mở thường dùng làm baseline. Qwen2.5-VL hỗ trợ định vị sự kiện theo thời gian, phù hợp với yêu cầu chỉ ra mốc bằng chứng. Mô hình chuyên cho tai nạn: AdVersa-SD [11] suy luận chuỗi nguyên nhân – kết quả. TABot [7] huấn luyện đa nhiệm cả nhận

diện và định vị tai nạn. SeeUnsafe [6] dùng MLLM để sàng lọc video camera giao thông ở quy mô lớn. Trả lời có bằng chứng: NExT-GQA [10] buộc mô hình vừa trả lời vừa chỉ ra đoạn video bằng chứng. Chọn khung hình bằng suy luận hoặc học tăng cường: A.I.R. [19] chọn khung hình lặp mà không cần huấn luyện. Video-R1 [20] dùng học tăng cường cho suy luận trên video. Đây là nền tảng cho phương pháp đề xuất.

Khoảng trống

Mỗi bộ dữ liệu trên đáp ứng một phần yêu cầu, nhưng chưa bộ nào kết hợp đồng thời ba yếu tố: (1) video tai nạn ở dòng xe hỗn hợp có nhiều xe máy như Việt Nam, (2) câu trả lời dạng tự do và (3) mốc thời gian bằng chứng cho từng câu.

Đối tượng sử dụng

Lực lượng CSGT (hướng ứng dụng tiềm năng). Hệ thống không nhằm thay cán bộ xem một đoạn video. Giá trị của nó nằm ở hai việc. Thứ nhất là sàng lọc khối lượng lớn video từ camera giám sát chạy liên tục, là việc mà con người khó làm thủ công [6]. Thứ hai là tạo bản tóm tắt có cấu trúc kèm mốc khung hình bằng chứng để tra cứu lại.

Cơ sở đào tạo lái xe. Thông tư 04/2022/TT-BGTVT yêu cầu cơ sở đào tạo sử dụng phần mềm mô phỏng tình huống giao thông [21]. Thông tư 17/2026/TT-BXD vẫn giữ nội dung học 4 giờ với 120 tình huống mô phỏng trong chương trình đào tạo [22], dù bài thi mô phỏng đã bị bỏ khỏi kỳ sát hạch từ ngày 01/7/2026 [23]. Nghiên cứu quốc tế cho thấy huấn luyện nhận diện nguy hiểm bằng video giúp người lái mới cải thiện kỹ năng [24, 25]. Tuy nhiên, 120 tình huống hiện có là video mô phỏng dựng lại. Bộ dữ liệu video tai nạn thực tế tại Việt Nam kèm giải thích có thể là học liệu bổ sung.

Mục tiêu của đề tài:

Mục tiêu 1: Xây dựng bộ chuẩn đánh giá VN-TA-VQA chất lượng cao: Xây dựng thành công bộ dữ liệu gồm 3.000 đoạn video và 27.000 cặp câu hỏi - đáp án được phân loại theo phân loại 9 nhóm nội dung. Mỗi cặp hỏi - đáp được gắn kèm mốc thời gian bằng chứng xác thực.

Mục tiêu 2: Xây dựng quy trình đánh giá tự động tin cậy: Phát triển bộ chấm điểm tự do kết hợp mô hình ngôn ngữ lớn và mô hình thị giác - ngôn ngữ, áp dụng phương pháp tối ưu hóa câu lệnh tự động GEPA và xác thực độ tương quan với đánh giá của người thật đạt hệ số Spearman từ 0.8 trở lên trên tất cả các nhóm câu hỏi.

Mục tiêu 3: Đề xuất phương pháp cải tiến mô hình: Đề xuất phương pháp lựa chọn khung hình bằng học tăng cường, chứng minh hiệu quả vượt trội so với các phương pháp cơ sở trên bộ chuẩn VNTA-VQA.

Phương pháp thực hiện:

Phương pháp thực hiện của đề tài được triển khai qua một quy trình hệ thống, bắt đầu từ giai đoạn thu thập và tiền xử lý dữ liệu. Các đoạn video tai nạn giao thông được tổng hợp từ các nguồn công khai (Youtube), sau đó trải qua bước sàng lọc khắt khe dựa trên tiêu chí về chất lượng hình ảnh, độ dài thời gian (5-30s). Những video đạt chuẩn tiếp tục được tiền xử lý như là ẩn danh hóa toàn bộ thông tin biển số xe, khuôn mặt nhằm đảm bảo tuyệt đối quyền riêng tư.

Sau quá trình tiền xử lý, dữ liệu được đưa vào quy trình gán nhãn dựa trên hệ thống phân loại gồm 9 nhóm câu hỏi. Giai đoạn này được định hướng bởi một bộ quy tắc gán nhãn chi tiết, trong đó thiết lập các ràng buộc chặt chẽ về mặt đạo đức và pháp lý, đặc biệt đối với các nhóm câu hỏi liên quan đến vi phạm hay quy kết trách nhiệm pháp lý. Nhằm tối ưu hóa nguồn lực, đề tài áp dụng cơ chế gán nhãn bán tự động: các mô hình thị giác - ngôn ngữ (VLM) đóng vai trò sinh câu hỏi và đáp án nháp, tiếp đó đội ngũ gán nhãn sẽ tiến hành kiểm tra, chỉnh sửa và xác thực chéo. Chất lượng của bộ dữ liệu được kiểm soát nghiêm ngặt thông qua việc đo lường độ đồng thuận giữa những người gán nhãn (inter-annotator agreement).

Để đánh giá khách quan năng lực của các mô hình trên bộ dữ liệu vừa xây dựng, đề tài thiết lập một khung chấm điểm tự động. Các câu lệnh điều khiển (prompt) dành cho mô hình giám khảo (LLM/VLM judge) được tối ưu hóa liên tục bằng thuật toán GEPA. Khung đánh giá này sau đó được sử dụng để tiến hành thực nghiệm (benchmark) hàng loạt các mô hình VideoQA hiện hành. Kết quả thực nghiệm được đo lường bằng các chỉ số chuyên biệt dành cho định dạng văn bản tự do, đồng thời được phân tích chuyên sâu theo từng nhóm taxonomy nhằm đánh giá chính xác mức độ thách thức của mỗi loại câu hỏi đối với trí tuệ nhân tạo.

Từ những phân tích thực nghiệm, đề tài tiến hành đề xuất phương pháp cải tiến mô hình nhằm khắc phục các hạn chế hiện tại. Phương pháp này là sự giao thoa của hai kỹ thuật cốt lõi: lựa chọn khung hình bằng học tăng cường để bám sát các mốc thời gian chứa bằng chứng, và chắt lọc chuỗi suy luận giả định nhằm tăng cường tính logic, minh bạch trong quá trình suy luận của mô hình.

Phân loại 9 nhóm câu hỏi:

Mã	Nhóm câu hỏi	Câu hỏi đại diện	Đối tượng	Đặc điểm & Độ khó
S	Bối cảnh (Scene)	Thời tiết, ánh sáng, loại đường và tình trạng mặt đường ra sao?	Cả hai	Khách quan cao
E	Thực thể (Entities)	Loại phương tiện và màu sắc của các bên liên quan là gì?	Cả hai	Khách quan cao
N	Diễn biến (Narrative)	Hãy tóm tắt toàn bộ diễn biến sự kiện xảy ra trong video.	Cả hai	Độ khó vừa
C	Nguyên nhân (Causal)	Nguyên nhân trực tiếp hoặc hành động ngay trước va chạm là gì?	Cả hai	Độ khó vừa
V	Vi phạm (Violation)	Có hành vi vi phạm quy tắc giao thông nào quan sát được không?	Điều tra	Độ khó vừa
O	Hậu quả (Outcome)	Hậu quả va chạm và mức độ hư hỏng quan sát được là gì?	Cả hai	Khách quan
R	Ứng xử (Response)	Hành vi của các bên sau tai nạn là gì (dừng lại, bỏ chạy, hỗ trợ)?	Điều tra	Độ khó vừa


Attr	Quy trách nhiệm (Attribution)	Bên nào đóng vai trò chính dẫn đến va chạm dựa trên bằng chứng thị giác?	Điều tra	Chủ quan
Prev	Phòng tránh (Prevention)	Người điều khiển phương tiện nên làm gì để phòng tránh va chạm này?	Đào tạo	Chuẩn tắc, Đa đáp án

Quy trình xây dựng và gán nhãn dữ liệu:

Bước	Tên bước thực hiện	Dữ liệu đầu vào	Kết quả đầu ra
1	Thu thập dữ liệu	Video thô từ camera hành trình, CCTV, mạng xã hội	Kho video thô ban đầu
2	Lọc, ẩn danh và cắt clip	Video thô thu thập	Các clip 5–30 giây đã làm mờ biển số và khuôn mặt
3	Sinh câu hỏi - đáp án nháp	Clip đã xử lý tiền kỳ	Tập hỏi - đáp nháp thuộc 9 nhóm và mốc thời gian đề xuất
4	Kiểm tra danh mục yêu cầu	Tập hỏi - đáp nháp	Bộ hỏi - đáp đạt chuẩn
5	Xây dựng hướng dẫn gán	Bộ hỏi - đáp và bảng phân loại	Bộ tiêu chí gán nhãn, tiêu chí mốc thời gian và độ tin cậy

	nhân		
6	Đánh giá đồng thuận nhóm B	Video, bộ hỏi - đáp và hướng dẫn	Kết quả bỏ phiếu đa số (từ 3 người trở lên) và chọn mốc thời gian
7	Tính tỷ lệ đồng thuận	Kết quả bỏ phiếu nhóm B	Tỷ lệ đồng thuận theo nhóm và chỉ số trùng khớp mốc thời gian
8	Chốt dữ liệu chuẩn	Tỷ lệ đồng thuận và kết quả bỏ phiếu	Bộ dữ liệu chuẩn hoàn chỉnh, loại bỏ các câu không đạt
9	Xây dựng & xác thực bộ chấm	Dữ liệu chuẩn và điểm người chấm	Bộ chấm điểm tự động đạt hệ số tương quan Spearman từ 0.8 trở lên
10	Chia tập dữ liệu	Dữ liệu chuẩn đã kiểm định	Tập huấn luyện, xác thực và kiểm thử kèm báo cáo thống kê
11	Thực nghiệm & đánh giá	Bộ dữ liệu VN-TA-VQA hoàn chỉnh	Bảng kết quả so sánh mô hình cơ sở, phương pháp đề xuất và phân tích

RoadSceneVQA-VN: Quy trình xây dựng dữ liệu và đánh giá



Hình 1 Sơ đồ minh họa quy trình gán nhãn và kiểm soát chất lượng dữ liệu

Xây dựng prompt đánh giá:

Câu trả lời là dạng tự do nên không thể so khớp từng chữ (exact-match). Vì vậy cần một “người chấm” tự động (judge) đáng tin. Trước khi dùng judge chấm thí nghiệm chính, phải kiểm tra xem nó có chấm giống người hay không.

Mỗi nhóm câu hỏi dùng một prompt riêng, không dùng chung:

Prompt #1 (S/E/N/O): chấm chặt. Đáp án chuẩn (GT) đã đủ chi tiết, nên judge chỉ cần so xem ý nghĩa của câu trả lời có trùng GT không.

Prompt #2 (C/V/R): kiểm tra chuỗi nguyên nhân – kết quả và thứ tự thời gian của các sự kiện.

Prompt #3 (Attr): chấm theo đáp án đa số. Chấp nhận các cách diễn đạt khác nhau nếu cùng chỉ ra đúng bên đóng vai trò chính và hành vi dẫn đến va chạm.

Prompt #4 (Prev): chấp nhận nhiều đáp án đúng. Trả lời đúng một phần thì được điểm một phần.

Vòng lặp kiểm tra và cải thiện prompt (dùng GEPA):

Vòng lặp kiểm tra và cải thiện câu lệnh (prompt) được thực hiện thông qua công cụ tự động hóa GEPA [26]. Cơ chế hoạt động của GEPA cho phép mô hình ngôn ngữ

lớn tự động đọc các lỗi đánh giá đã mắc phải, đưa ra nhận xét bằng ngôn ngữ tự nhiên và viết lại một câu lệnh mới tối ưu hơn. Quy trình này bắt đầu bằng việc trích xuất ngẫu nhiên khoảng 50 cặp dữ liệu từ tập đáp án chuẩn (Ground Truth). Kế tiếp, một mô hình phụ (proxy model) được sử dụng để sinh ra các câu trả lời giả định với chất lượng phân hóa đa dạng từ đúng, đúng một phần cho đến sai hoàn toàn. Tập dữ liệu mẫu này sau đó được chấm điểm độc lập trên thang từ 1 đến 5 bởi cả người gán nhãn và bộ chấm tự động (bao gồm LLM judge và VLM judge). Để đánh giá năng lực của bộ chấm, hệ số tương quan Spearman ρ giữa điểm số của con người và máy tính được tính toán riêng cho từng nhóm câu hỏi. Hệ số ρ càng tiệm cận 1 chứng tỏ khả năng đánh giá và xếp hạng của máy càng sát với tư duy của con người. Nếu bất kỳ nhóm nào ghi nhận hệ số $\rho < 0.8$, thuật toán GEPA sẽ được kích hoạt để phân tích lỗi, sửa lại câu lệnh của nhóm đó và lặp lại quy trình chấm điểm. Quá trình tinh chỉnh này chỉ kết thúc khi tất cả các nhóm câu hỏi đều đạt ngưỡng tương quan $\rho \geq 0.8$, các câu lệnh tối ưu nhất lúc này sẽ được lưu lại và áp dụng chính thức cho toàn bộ khâu thực nghiệm của đề tài.

Phương pháp đề xuất cải tiến mô hình:

Phương pháp nghiên cứu đề xuất của đề tài kết hợp hai kỹ thuật cốt lõi: Lựa chọn khung hình bằng học tăng cường và Chắt lọc chuỗi suy luận giả định.

Trong kỹ thuật Lựa chọn khung hình bằng học tăng cường (RL Keyframe Selection), thay vì lấy mẫu khung hình đều đặn theo thời gian, mô hình được huấn luyện để tự động trích xuất từ 1 đến 3 khung hình chứa bằng chứng quan trọng nhất liên quan đến câu hỏi. Mô hình trải qua giai đoạn huấn luyện khởi đầu bằng học có giám sát (SFT), sau đó được tối ưu bằng học tăng cường với hàm thưởng đa mục tiêu kết hợp giữa độ chính xác của câu trả lời, độ lệch mốc thời gian bằng chứng (đo lường bằng độ giao thoa - IoU với mốc thời gian thực tế).

Trong kỹ thuật Chắt lọc chuỗi suy luận giả định (Pseudo-CoT Distillation), mô hình mạnh (ví dụ như GPT-4o Vision) sinh ra chuỗi suy luận có cấu trúc chặt chẽ cho tập huấn luyện theo các bước logic tuần tự: phân tích bối cảnh, nhận diện thực thể, phân tích trình tự thời gian, xác định nguyên nhân nhân quả, trích xuất mốc thời gian trước khi đưa ra kết luận cuối cùng. Mô hình học sinh (ví dụ Qwen2.5-VL) được huấn luyện để chắt lọc tri thức này thông qua bước tinh chỉnh có giám sát.

Metrics đánh giá:

Judge Score (chính): từ judge đã validate, báo cáo per nhóm.

Grounding Accuracy: % câu có ít nhất 1 predicted keyframe trong GT ± 2 frame.

Agreement Rate: % majority vote đồng thuận từ Team B, per nhóm.

Faithfulness: % câu answer thay đổi khi bỏ CoT keyframe reasoning.

BLEU / BERTScore (phụ): báo cáo để so sánh với baseline cũ; không dùng làm metric chính.

Các mô hình đánh giá:

GPT-4o (OpenAI): Mô hình SOTA toàn diện với khả năng lập luận nhân - quả vượt trội, dùng làm thước đo chuẩn cao nhất.

Qwen2.5-VL: Mô hình hỗ trợ tiếng Việt tốt nhất hiện nay trong nhóm mã nguồn mở, xử lý video linh hoạt, lý tưởng để tinh chỉnh (SFT/RL).

InternVL-2.5: Năng lực nhận diện chi tiết hình ảnh khắt khe (biển báo, đèn tín hiệu, vật thể ở xa) tiệm cận mô hình thương mại.

LLaVA-OneVision: Kiến trúc chuyên biệt cho video, đặc biệt mạnh trong việc theo dõi chuỗi diễn biến và hành động.

Video-LLaMA 2: Nổi bật với khả năng mô hình hóa chuỗi sự kiện động theo thời gian thực.

VideoChat2: Một baseline tiêu chuẩn, ổn định và phổ biến trong cộng đồng nghiên cứu VideoQA.

PLLaVA (Pooling LLaVA): Tối ưu hóa việc gộp đặc trưng từ nhiều khung hình, rất phù hợp cho bài toán trích xuất bằng chứng (keyframe).

Tài liệu tham khảo

- [1] Alayrac, J.-B., et al. (2022). Flamingo: A visual language model for few-shot learning. Advances in Neural Information Processing Systems (NeurIPS 2022).
- [2] Liu, H., Li, C., Wu, Q., & Lee, Y. J. (2023). Visual instruction tuning. Advances in Neural Information Processing Systems (NeurIPS 2023).
- [3] Zhang, H., Li, X., & Bing, L. (2023). Video-LLaMA: An instruction-tuned audio-visual language model for video understanding. Proceedings of EMNLP 2023: System Demonstrations.
- [4] Fu, C., et al. (2025). Video-MME: The first-ever comprehensive evaluation benchmark of multi-modal LLMs in video analysis. Proceedings of CVPR 2025.
- [5] Google DeepMind. (2025). Gemini 2.5 Pro Preview (I/O Edition): kết quả trên VideoMME. Bài công bố của Google, tháng 5/2025 (nguồn phụ).

- [6] Zhang, R., Wang, B., Zhang, J., Bian, Z., Feng, C., & Ozbay, K. (2025). When language and vision meet road safety: Leveraging multimodal large language models for video-based traffic accident analysis. *Accident Analysis & Prevention*, 219, 108077. doi:10.1016/j.aap.2025.108077
- [7] Zhou, Y., et al. (2025). TAU-106K: A new dataset for comprehensive understanding of traffic accident. *International Conference on Learning Representations (ICLR 2025)*.
- [8] Kim, J., Abdelrahman, A., & Abdel-Aty, M. (2025). VRU-Accident: A vision-language benchmark for video question answering and dense captioning for accident scene understanding. *Proceedings of ICCV Workshops 2025*, pp. 761–771.
- [9] Gan, et al. (2026). CrashSight. *Proceedings of CVPR Workshops 2026*, pp. 718–727.
- [10] Xiao, J., Yao, A., Li, Y., & Chua, T.-S. (2024). Can I trust your answer? Visually grounded video question answering. *Proceedings of CVPR 2024*, pp. 13204–13214. doi:10.1109/CVPR52733.2024.01254
- [11] Fang, J., et al. (2024). Abductive ego-view accident video understanding for safe driving perception. *Proceedings of CVPR 2024*, pp. 22030–22040.
- [12] Yao, Y., et al. (2023). DoTA: Unsupervised detection of traffic anomaly in driving videos. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(1), 444–459.
- [13] Xu, L., Huang, H., & Liu, J. (2021). SUTD-TrafficQA: A question answering benchmark and an efficient network for video reasoning over traffic events. *Proceedings of CVPR 2021*, pp. 9878–9888. doi:10.1109/CVPR46437.2021.00975
- [14] Asian Transport Observatory. (2025). Viet Nam Road Safety Profile 2025.
- [15] World Health Organization Viet Nam. (2024). Thông tin về an toàn giao thông đường bộ.
- [16] Guan, et al. (2026). RoadSceneVQA. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40(6), 4366–4375. doi:10.1609/aaai.v40i6.42434
- [17] Chen, Z., et al. (2024). InternVL: Scaling up vision foundation models and aligning for generic visual-linguistic tasks. *Proceedings of CVPR 2024*.
- [18] Bai, S., et al. (2025). Qwen2.5-VL technical report. arXiv:2502.13923.

- [19] Zou, et al. (2026). A.I.R. International Conference on Learning Representations (ICLR 2026). arXiv:2510.04428.
- [20] Feng, K., et al. (2025). Video-R1: Reinforcing video reasoning in MLLMs. Advances in Neural Information Processing Systems (NeurIPS 2025). arXiv:2503.21776.
- [21] Bộ Giao thông vận tải. (2022). Thông tư 04/2022/TT-BGTVT.
- [22] Bộ Xây dựng. (2026). Thông tư 17/2026/TT-BXD.
- [23] Bộ Công an. (2026). Thông tư 108/2026/TT-BCA.
- [24] Isler, R. B., Starkey, N. J., & Williamson, A. R. (2009). Video-based road commentary training improves hazard perception of young drivers in a dual task. *Accident Analysis & Prevention*, 41(3), 445–452.
- [25] Prabhakharan, P., et al. (2024). The efficacy of hazard perception training and education: A systematic review and meta-analysis. *Accident Analysis & Prevention*, 202, 107554.
- [26] Agrawal, et al. (2026). [Reflective Prompt Evolution Can Outperform Reinforcement Learning]. International Conference on Learning Representations (ICLR 2026 - Oral).

Kế hoạch thực hiện (Mô tả kế hoạch làm việc và phân công công việc cho từng sinh viên tham gia):

Tuần	Thời gian	Sinh viên Nguyễn Minh Quốc	Sinh viên Nguyễn Văn Quyền
1–2	07/09 – 20/09/2026	Thu thập video tai nạn giao thông, thực hiện cắt clip và làm mờ thông tin cá nhân	Cài đặt môi trường annotation, chuẩn hóa cấu trúc thư lưu trữ dữ liệu
3–4	21/09 – 04/10/2026	Sinh câu hỏi - đáp án nháp bằng mô hình thị giác - ngôn ngữ cho 5 nhóm đầu	Sinh câu hỏi nháp cho 4 nhóm sau và xây dựng bộ hướng dẫn gán nhãn chi tiết
5–6	05/10 – 18/10/2026	Tham gia bỏ phiếu đa số nhóm B, gán mốc thời gian bằng chứng cho tập dữ liệu	Kiểm soát chất lượng bỏ phiếu, tính tỷ lệ đồng thuận.
7	19/10 – 25/10/2026	Thực hiện xây dựng và xác thực bộ chấm tự động, tối ưu câu lệnh bằng thuật toán GEPA	Hỗ trợ chuẩn hóa tập dữ liệu thử nghiệm và thu thập điểm đánh giá từ người thật
8	26/10 – 01/11/2026	Hỗ trợ thiết lập môi trường chạy thử nghiệm các mô hình tham chiếu	Thực hiện chia tập Train/Val/Test và chạy các mô hình cơ sở A1, A2, Ref-1, Ref-

			2
9	02/11 – 08/11/2026	Sinh chuỗi suy luận giả định bằng mô hình GPT- 4o Vision và chạy bộ lọc trung thực	Chuẩn hóa dữ liệu chuỗi suy luận và chuẩn bị tài nguyên huấn luyện mô hình học sinh
10	09/11 – 22/11/2026	Hỗ trợ phân tích kết quả huấn luyện tinh chỉnh có giám sát	Thực hiện huấn luyện tinh chỉnh mô hình học sinh và chạy các thử nghiệm A3, A4, A5
11	23/11 – 06/12/2026	Cài đặt và thực hiện thuật toán lựa chọn khung hình bằng học tăng cường (A6– A8)	Phân tích kết quả thực nghiệm theo 5 câu hỏi nghiên cứu và tổng hợp bảng số liệu
12	07/12 – 26/12/2026	Viết báo cáo khóa luận phần phương pháp, thực nghiệm và hoàn thiện hệ thống demo	Viết báo cáo phần tổng quan, bộ dữ liệu, chuẩn bị tài liệu và slide bảo vệ

Xác nhận của CBHD (Ký tên và ghi rõ họ tên) TS. Đỗ Trọng Hợp ThS. Nguyễn Ngọc Quý	TP. HCM, ngày 24 tháng 09 năm 2026 Sinh viên (Ký tên và ghi rõ họ tên) Nguyễn Minh Quốc Nguyễn Văn Quyền
---	--